2022年春季学期《编译原理》大作业

第23组 组长: 李丰杰 组员: 周磊 高乐瑜

词法分析器设计文档

词法分析器整体的设计步骤是:

- 1. 根据提供的标准写出各种识别类型的正则表达式
- 2. 将正则表达式转化为NFA
- 3. 将各个NFA连接起来,形成最终的NFA
- 4. 将NFA输入NFA确定化算法得到DFA, 然后DFA最小化.
- 5. 逐行读入文件,每行按字符读入DFA,直到找到对应终结状态或出错.

• 数据结构

下面是词法分析器用到的数据结构:

```
vector<string> KeyWord; // 存放文档中要求的27个关键字
vector<string> OP; // 存放文档中要求的13个运算符
vector<string> SE; // 存放文档中要求的3个界符

struct dfa_status{
    int no; // 状态编号
    int term; // 是否为终结符 0
};
vector<dfa_status> dfa_all_status; // 存放dfa的所有状态

vector<int> nfa_matrix[Num_status][Num_edge]; // 存放nfa的矩阵
// 矩阵中i行j列的元素表示 状态i经过输入j可以达到的状态集合

int dfa_martix[Num_status][Num_edge]; // 存放dfa的矩阵
// 矩阵中i行j列的元素表示 状态i经过输入j可以达到的状态

int dfa_min_martix[Num_status][Num_edge]; // 存放最小化dfa的矩阵
// 矩阵中i行j列的元素表示: 状态i经过输入j可以达到的状态
```

```
set<int> stop_status = {4, 12, 14, 24, 31, 32, 33, 35, 37, 39, 42, 44, 46, 47, 48, 49, 50, 54, 55, 56}; // nfa中的终结状态.

map<char, int> edges; // 边集合, 使用关联容器将输入元素与矩阵的列数对应起来.
```

• Build NFA算法

我们的词法分析器是根据人工写出正则表达式然后转换为nfa作为输入的,因此在项目中存在一个 nfa.txt 文件, 里面存放着我们生成的nfa文件. Build NFA算法就是读入nfa文件,填充 nfa_martix 矩阵,并根据不同状态间转换的字符构造 edges 边集合:

```
void build_nfa(std::ifstream& nfa){
    string line; // read line
    string temp1; char temp; string temp2;
    // status1, input char, status2
    int s1,s2;
    int counter_token = 0;
    while(std::getline(nfa, line)){
        stringstream input(line);
        input >> temp1; input>> temp; input >> temp2;
        // 使用stringstream来便捷地格式化数据.
        if(edges.count(temp) == 0){
            // 如果该input字符还未出现过,加入map中
            edges.insert(std::make_pair(temp, counter_token));
            counter_token++;
        }
        // 将状态转换存入nfa矩阵
        s1 = std:: stoi(temp1); s2 = std:: stoi(temp2);
        nfa_matrix[s1-1][edges[temp]].push_back(s2);
    }
    return;
}
```

• NFA to DFA算法

我们使用课上讲述的使用 ε 闭包的方式将NFA转换为DFA, 基本思想是:

- 1. 首先从 S_0 出发,仅经过任意条 ε 条箭弧所能达到的状态组成的集合叫做初态 q_0
- 2. 分别从 q_0 出发,经过任意 $a\in \sum$ 的a弧转换 I_a 所组成的集合作为DFA的状态,如此继续,直到不再有新状态产生.

因此, 我们首先要做的就是完成a弧转换的实现:

因为 $I_a=\varepsilon-closure(move(I,a))$,因此我们需要得到move(I,a)即所有可以从状态I的某一状态经过一条a弧而到达的状态的全体.

```
set<int> moveia(set<int> init, int input)
{
    set<int> outcome;
    // 计算当前状态通过各个输入字符的可达节点
    set<int>::iterator it;
    for(it=init.begin(); it !=init.end(); ++it){
        // 如果nfa矩阵对应元素不为空,那就加入到最终状态集中.
        for (int j = 0; j < nfa_matrix[(*it)-1][input].size(); ++j){
            outcome.insert(nfa_matrix[(*it)-1][input][j]);
        }
    }
    return outcome;
}
```

接下来是对 ε 闭包的计算,由于该算法是硬编码到我们的词法分析器中的,因为在nfa中我们使用 @ 代表 ε ,且在nedges数据结构中,该输入对应的数字是 $\frac{1}{2}$,所以你会看到我们只针对nfa矩阵的下标为1的列进行操作.

```
set<int> closuer(set<int> init, int input)
{

// 对init的每一个状态,都寻找@可达状态

// 生成闭包

set<int> temp = moveia(init, input); // 先计算 move(I,a)

set<int>::iterator it;

for(it =temp.begin(); it!=temp.end(); ++it){

    // 针对其中的每个元素,都寻找其按@可以到达的状态

    // 然后将这个状态插入到temp集中,继续找@可达的状态

    // 借此实现经过任意条@边的操作,且其为一个set,可自动去重。
    for(int n=0; n < nfa_matrix[(*it)-1][1].size(); ++n)

        temp.insert(nfa_matrix[(*it)-1][1][n]);

}

return temp;
}
```

最后就是把所有组件拼在一起的操作了:

```
void nfa2dfa()
{
```

```
set<int> init= {1};// 我们nfa的起始状态只有1
vector< set<int> > all_states; // 辅助数据结构, 用于遍历和去重.
dfa_all_status.push_back({1,false}); // 记录状态编号和是否为终结状态
while(true){
   for(int input =0; input< Num_edge; ++input){</pre>
       if (input == 1) continue; // 此时就没有@的输入了
       set<int> outcome = closuer(all_states[current], input); // 求闭包
       if(outcome.size()==0) continue;
       if(find(all_states.begin(), all_states.end(), outcome)==all_states.end())
           all_states.push_back(outcome);
           for(it= outcome.begin(); it!=outcome.end(); ++it){
             // 遍历看是否为终结状态
           dfa_all_status.push_back(标号);// 按顺序标号
       }else{
   current++;
   if(current == all_states.size())
       break;
Dfa_status = all_states.size(); // 记录总状态数
```

• DFA最小化算法

算法的核心思想就是: 把DFA的状态集k分割为不相交的子集.

DFA M =(S,Σ, δ, s0, St), 最小状态为DFA M'

步骤如下:

- 1. 构造状态的初始划分 Π :终态 S_t 和非终态 $S S_t$ 两组
- 2. 对 Π 施用传播性原则构造新划分 Π_{new}
- 3. 如 $\Pi_{new} == \Pi$,则令 $\Pi_{final} = \Pi$ 并继续步骤4,否则 $\Pi = \Pi_{new}$ 重复步骤2
- 4. 为 Π_{final} 中的每一组选一个代表, 这些代表构成M'的状态。若s是一代表,且 $\delta(s,a)=t$, 令r是t组的代

表,则M'中有一转换 $\delta'(s,a)=r$. M'的开始状态是含有 s_0 的那组的代表, M'的终态是含有 s_t 的那组的代表.

5. 去掉M'中的死状态

对 Π 施用传播性原则构造新划分 Π_{new} 步骤:

"

- 假设 Π 被分成m个子集 $\Pi = \{S_1, S_2, \dots, S_m\}$,且属于不同子集的状态是可区别的,检查 Π 的每一个子集 S_i ,看是否能够进一步划分.
- 对于某个 S_i , 令 $S_i = \{s_1, s_2, \ldots, s_k\}$, 若存在数据字符a使得 I_a 不全包含在现行 Π 的某一子集Sj 中,则将Si 一分为二:即假定状态 s_1, s_2 ,经过a弧分别达到状态 t_1, t_2 , 且 t_1, t_2 属于现行 Π 的两个不同子集,那么将 S_i 分成两半,一半含有

 $s1: S_{i1} = \{s | s \in S_i \exists s \leq a$ 孤到达 t_1 所在子集中的某状态 $\}; 另一半含有<math>s2: S_{i2} = S_i - S_{i1}.$

- 由于 t_1, t_2 是可区别的,即存在w, 使得 t_1 读出w而停于终态, t_2 读不出w或读出w却未停于终态。因而aw可以将 s_1, s_2 区分开。也就是说 S_{i1} 和 S_{i2} 中的状态时可区别的.
- $\Pi_{new} = \{S_1, S_2, \dots, S_{i1}, S_{i2}, \dots, S_m\}$

```
}else{
            if(new_set.size()>0)
                all.insert(all.begin()+i+1, new_set);
    for(int i=0; i< all.size(); ++i){</pre>
        set<int>::iterator it;
        if(all[i].size() > 1){
            it = all[i].begin();
            for(; it!=all[i].end(); ++it){
                 for(int m=0; m< Dfa_status; ++m){</pre>
                     for(int n=0; n< Num_edge; ++n){</pre>
                         if (all[i].count(m)!=0){
                         else if(std::abs(dfa_min_martix[m][n])==*it)
                             dfa_min_martix[m][n] = dfa_min_martix[m][n] >0 ? temp :
-1*temp;
    return;
```

SCAN算法

在生成DFA后, 我们就可以利用该DFA针对输入字符进行一系列的状态变换, 实现识别出输入字符或者报错: 在识别输入字符的过程中, 有以下几种特殊情况:

- 1. 首先判断, 如果当前已经识别出GROUP 或ORDER, 那么新输入的B和Y就不会按char字符进行处理, 而是一个特殊的边.
- 2. 如果当前已经读入一个 字符, 那么就开始字符串识别, **按文档要求**, 在识别字符串的过程中将所有输入(除了 与行终结符)均作为字符读入, 即可以容纳前述所有类型的字符.
- 3. 如果是其他合法的输入字符,那么就去 map<char ,int>edges 中寻找对应的状态编码.、

4. 如果上述所有情况均不满足,那么就认为是一个非法输入字符,词法分析器会报错.

在本词法分析器中,一次识别完成的标志是在读入一个字符后,状态机的当前状态回到 0 状态. 此时对状态进行识别: 判断是一个合法的串还是一个ERROR信息:

- 1. 首先判断串是否为文档中已经定义好的关键字,操作符,界符
- 2. 如果都不是,那么判断是否为标识符,整形数,浮点数,字符串等略微不确定的类型
- 3. 如果上述条件均不满足,那么就exit(-1),输出"ERROR NOT DEFINED INPUT:串"

```
int scan(std::ifstream& text)
   string line;
   while(std::getline(text, line)){
        int state = 1; // 起始状态
        for(int i =0; i < line.length(); ++i){</pre>
            buffer = line.substr(0,i);
            int input = judge(buffer, state, line[i]);
            if(input == -1){
                return -1;
            }else{
                state = std::abs(dfa_martix[state-1][input]);
                if(state ==0){
                    judge_final(buffer);
                    state =1 ;
                    if(line[0]==' ') line.erase(0, line.find_first_not_of(" "));
   return 0;
```

• 输出格式

正确输出格式:

- 关键字:[识别的关键字] < tab > < KW, 关键字序号(文档中标记) >
- 运算符: [识别的运算符] < tab > < OP, 运算符序号(文档中标记)>
- 界符: [识别的界符] < tab > <SE,界符序号(文档中标记)>
- 标识符:[识别的标识符] < tab > <IDN,识别的标识符>
- 整形数:[识别的整形数] < tab > <INT,识别的整形数>
- 浮点数: [识别的浮点数] < tab > < FLOAT,识别的浮点数>
- 字符串: [识别的字符串] < tab > < STRING,识别的字符串>

错误输出:

- 未定义输入字符: ERROR, ILLEGAL INPUT: 字符
- 未定义识别对象: ERROR NOT DEFINED INPUT:识别单词

• 编译步骤

您可以使用两种方式来完成词法分析器的编译与测试

方式1: 使用项目中的 Makefile 进行编译与测试.

```
cd ./src/lexical
make
//编译源代码, 生成可执行文件
make run
//运行我们提供的测试用例
make test
//运行验收时提供的测试用例
```

方式2: 手动输入命令进行测试

Hint: 你的所使用的c++编译器必须至少支持c++11标准, 目前使用g++和clang++编译并无问题

```
cd ./src/lexical/code
g++ -o lexical.out -std=c++11 main.cpp
   ./lexical.out ../test.txt > outcome.tsv
diff outcome.tsv ../standard.txt
```

语法分析器设计文档

语法分析器整体的设计步骤是:

- 1. 根据提供的标准写出各种识别类型的正则表达式
- 2. 根据初始符号构造第一个规范项目集闭包
- 3. 根据已有的规范项目集闭包计算新的规范项目集闭包,直达不会产生新的闭包,同时记录下状态转移,即go 表
- 4. 根据规范项目集簇和go表构建LR(1)分析表
- 5. 根据LR(1)分析表对输入串进行文法检查

• 数据结构

下面是文法分析器用到的数据结构:

```
struct Production //产生式
   vector<string> right;
};
struct Project //规范项目
   int location;
   set<string> predict;
};
   int closure_id;
   int next_id;
   string input;
};
struct ATItem { //分析表项
   bool b0, b1; //0,0表示accept, 1,1表示规约, 1,0表示移进, 0,1表示go
};
vector<string> Ts;
vector<string> Ns;
vector<map<string, ATItem>> ATable; //LR分析表
```

```
stack<string> AStack;//状态栈stack<int> SStack;//符号栈vector<Project> static_vp;//计算闭包时的临时储存buffer
```

• 求FIRST集

计算串 X1X2 ... Xn的FIRST集合

步骤如下:

"

- 1. 向FIRST(X1X2... Xn) 加入FIRST(X1)中所有的非ε符号
- 2. 如果ε在FIRST(X1) 中,再加入FIRST(X2)中的所有非ε符号;如果ε在FIRST(X1) 和 FIRST(X2)中,再加入FIRST(X3)中的所有非ε符号,以此类推...
- 3. 最后,如果对所有的X,ε都在FIRST(X)中,那么将ε加入到FIRST(X1X2...Xn)中

• CLOSURE运算,构造项目集规范族

假定I是文法G'的任一项目集,构造I的闭包 CLOSURE(I)的方法是:

- I的任何项目都属于CLOSURE(I);
- 若[A→α•Bβ, a]属于CLOSURE(I), B→η是一个产生式,那么,对FIRST(βa)中的每个终结符b,将[B→•η,b]加入CLOSURE(I);
- 重复上述两步骤直至CLOSURE(I)不再增大为止

```
伪代码

// 获取下一个closure

void Grammar:: getClosure(int index);

//根据输入符号和对应的项目进行闭包运算

set<Project> Closure(string next_s, vector<Project> vp);

//根据项目,扩充当前项目集

void expandClosure(Project temp_project);

//判断输入的规范集是否存在,不存在就添加到规范集簇中,都要返回规范集编号

int getNextClosure(set<Project> temp_closure);

//详情见代码注释
```

• 构造LR (1) 分析表

- 构造拓广文法G'的LR(1)项目集规范族C={I0,I1,...,In}
- 从Ik构造语法分析器的状态k, 状态k的分析动作如下:
- 如果[A→α·aβ, b]在Ik中,且GO(Ik, a)=Ij,则置action[k, a]为sj,即"移动(j, a)进栈",
 这里要求a必须是终结符
- 如果 $[A \rightarrow \alpha, a]$ 在 $[k \rightarrow n]$,则置[k, a]为[k, a]
- 如果[S'→S·, #]在Ik中,则置action[k, #]为acc,表示接受
- 状态k的转移按照下面的方法确定:如果GO(Ik, A)= Ij,那么goto[k, A]=i
- 其余表项设为出错
- 初始状态是包含[S'→·S, #]的项目集构造出的状态。

```
//构造分析表
void Grammar::getAnalyzeTable() {
   ATItem temp_item;
   map<string, ATItem> temp_row;
   int next_go;
   for (int i = 0; i < proj_fam.size(); i++) {
      for (auto j = proj_fam[i].begin(); j != proj_fam[i].end(); j++) {
       if (j->Ps_index == 0 && j->location == 1) {
          temp_item.b0 = 0;
          temp_item.b1 = 0;
          temp_item.index = 0; //acc
          temp_row["#"] = temp_item;
      }
}
```

```
else if (Ps[j->Ps_index].right.size() == j->location || Ps[j->Ps_index].right[0]
== "$") {
        for (auto k = j->predict.begin(); k != j->predict.end(); k++) {
          temp_item.b0 = 1;
          temp_item.b1 = 1;
          temp_item.index = j->Ps_index; //规约
          temp_row[*k] = temp_item;
     else {
        for (int k = 0; k < go_actions.size();k++) {</pre>
          if (go_actions[k].closure_id == i && go_actions[k].input == Ps[j-
>Ps_index].right[j->location]) {
           next_go = go_actions[k].next_id;
          }
        if (isT(Ps[j->Ps_index].right[j->location])) {
         temp_item.b0 = 1;
         temp_item.b1 = 0;
          temp_item.index = next_go; //移进
          temp_row[Ps[j->Ps_index].right[j->location]] = temp_item;
       else {
         temp_item.b1 = 1;
         temp_item.index = next_go; //go
         temp_row[Ps[j->Ps_index].right[j->location]] = temp_item;
   ATable.push_back(temp_row);
   temp_row.clear();
```

• 根据LR(1)分析表,移进规约输入串

分析栈中的串和等待输入的符号串构成如下形式的三元组: (S0S1S2...Sm, #X1X2...Xm, aiai+1 ...an#)

```
1.其初态为: (S0, #, a1a2 ...aiai+1...an#)
2.假定当前分析栈的栈顶为状态Sm,下一个输入符号为ai,分析器的下一个动作:
```

- 如果action[Sm, ai]=移进且S=GOTO[Sm,ai],则分析器执行移进, 三元组变成 (S0S1S2...SmS, #X1X2...Xmai, ai+1...an#)即分析器将输入符号ai和状态S移进栈, ai+1变成下一个符号;
- 如果action[Sm, ai]=归约A→β,则分析器执行归约, 三元组变成 (S0S1S2...Sm-rS, #X1X2...Xm-rA, aiai+1...
 an#), 此处S= GOTO[Sm-r, A], r为β的长度且β=Xm-r+1Xm-r+2...Xm;
- 若action[Sm,ai]=acc,则接收输入符号串,语法分析完成;
- 若action[Sm,ai]=err,则发现语法错误,调用错误恢复(直接返回)子程序进行处理。

```
void Grammar::grammarCheck(vector<string> inToken, string filename) {
 SStack.push(0);
 AStack.push("#");
 inToken.push_back("#");
 ofstream file;
 file.open(filename);
 if (!file) cout << "fail!打开结果文件失败" << endl;
 int nowState = 0;
 int inIndex = 0;
 int outSeq = 1;
 string nowSymbol;
 map<string, ATItem>::iterator it_item;
 while (inIndex < inToken.size()) {</pre>
   nowState = SStack.top();
   nowSymbol = inToken[inIndex];
   it_item = ATable[nowState].find(nowSymbol); //查找分析表, 不存在即出错
   if (it_item == ATable[nowState].end()) {
     cout << "Wrong!!!" << endl;</pre>
     return;
   temp_item = it_item->second;
   if (temp_item.b0 && temp_item.b1) {//规约
     if (Ps[temp_item.index].right[0] != "$") {
       int rl = Ps[temp_item.index].right.size();
        for (int i = 0; i < rl; i++) {
         SStack.pop();
         if (Ps[temp_item.index].right[rl - i - 1] == AStack.top()) AStack.pop();
         else {
```

```
cout << "ATable is wrong!!!" << endl;</pre>
            return;
      AStack.push(Ps[temp_item.index].left);
      SStack.push(ATable[SStack.top()][Ps[temp_item.index].left].index);
      file << outSeq << " " << temp_item.index << " " << AStack.top() << "#" <<
nowSymbol << " reduction" << endl;</pre>
    else if (temp_item.b0 && !temp_item.b1) { //移进
      SStack.push(temp_item.index);
     AStack.push(nowSymbol);
     inIndex++;
     file << outSeq << " / " << AStack.top() << "#" << nowSymbol << " move" << endl;</pre>
    else if (temp_item.b0 && !temp_item.b1) {
      cout << "wrong!!" << endl;</pre>
      return;
     file << outSeg << " / " <<"#"<<" " << "accept" << endl;
      return;
   outSeq++;
```

• LR分析表

由于表过于庞大,详情请见ATable.tsv文件

• 输出格式

正确输出格式:

- 全部[序号] [TAB] [选用规则序号或/] [TAB] [栈顶符号]#[面临输入符号] [TAB] [执行动作]
- accept

错误输出:

- 部分[序号] [TAB] [选用规则序号] [TAB] [栈顶符号]#[面临输入符号] [TAB] [执行动作]
- Wrong!!

• 编译步骤

• 直接利用VS自动编译功能,编译并运行代码